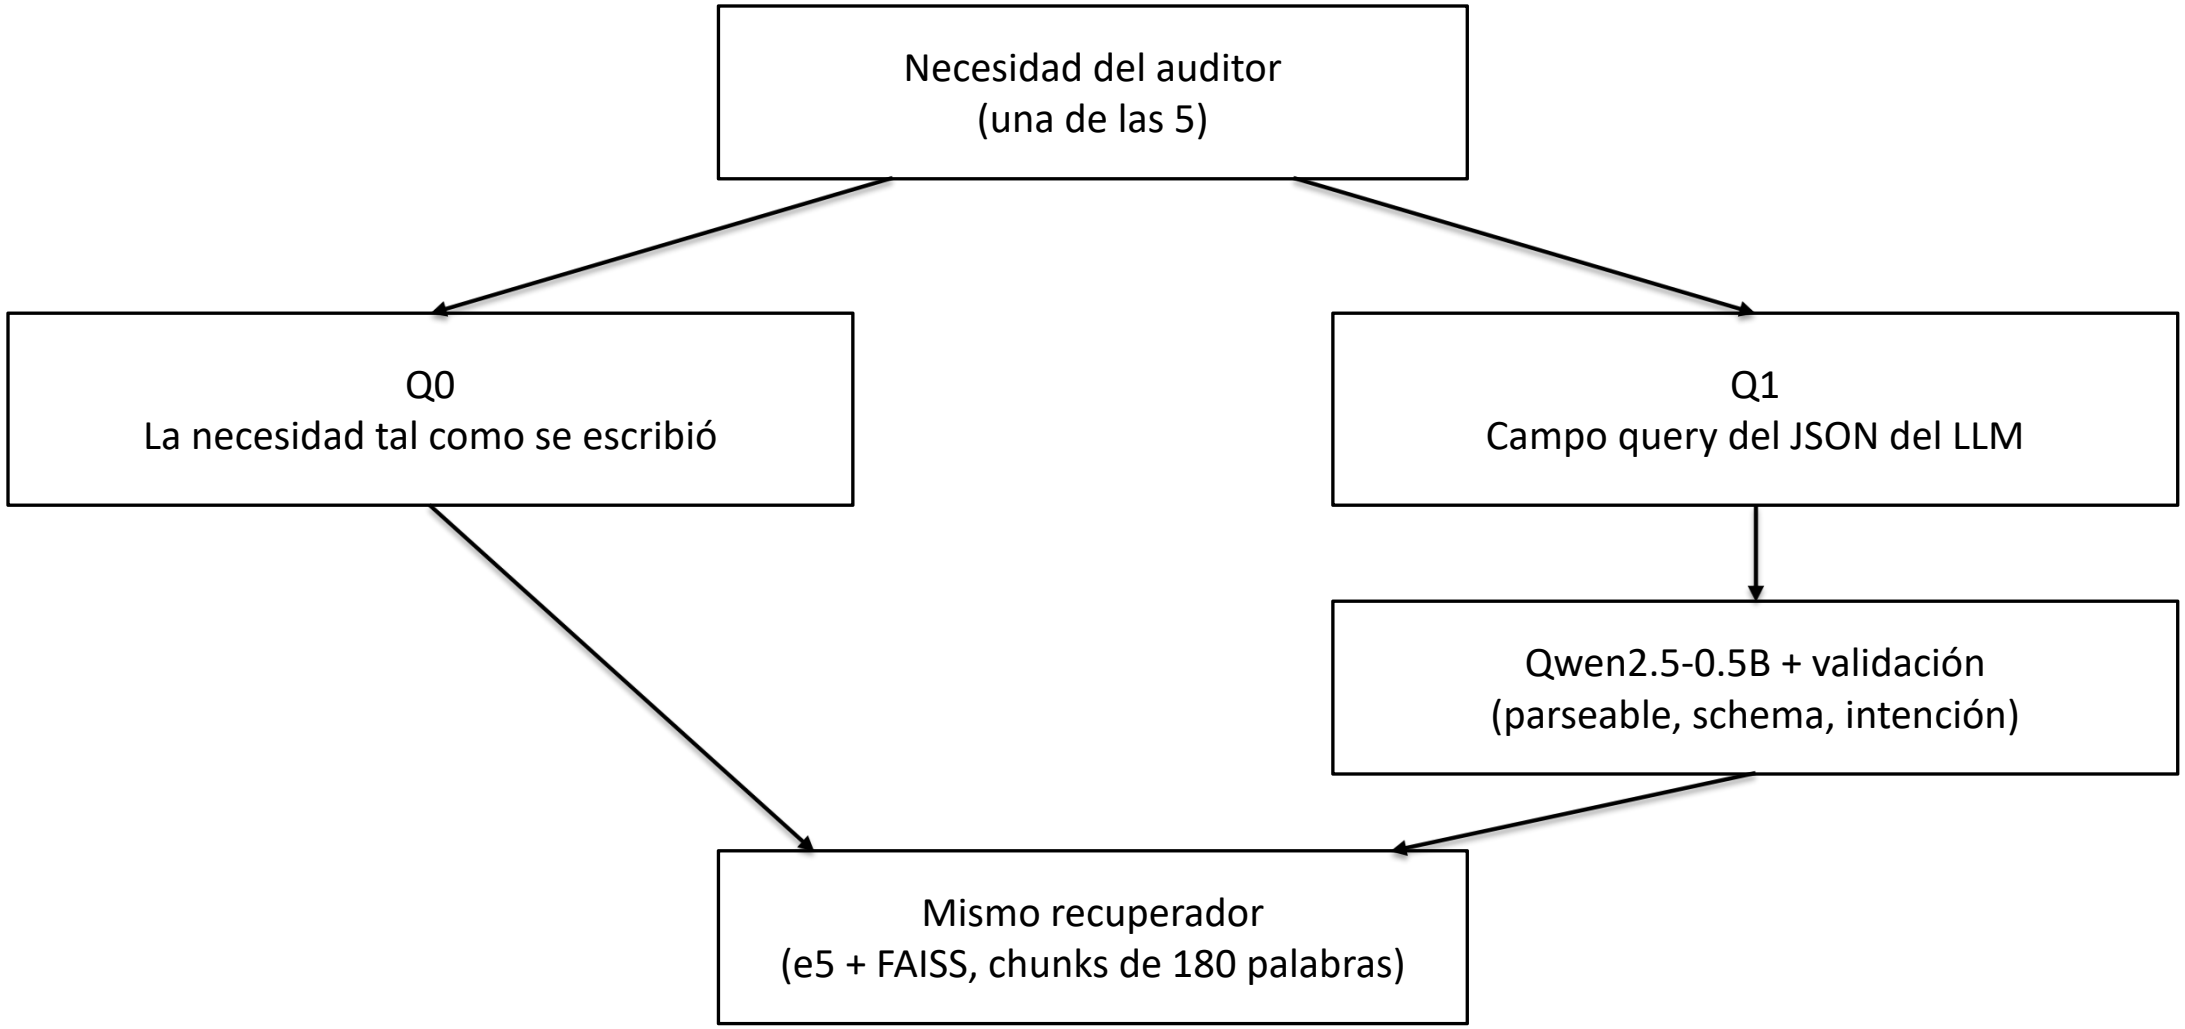
Experimento 1: consulta original vs consulta estructurada

PC2 - Tópicos de Ciencia de la Computación 1

¿De qué trata el experimento?

- El auditor escribe una necesidad de información en lenguaje natural
  - Ejemplo: ¿Qué empresa ganó la compra de reactivos para el equipo Mindray?
- Antes de buscar, un LLM la convierte en una consulta estructurada (un JSON)
- Pregunta: ¿esa transformación conserva, mejora o empeora lo que se quería encontrar?
- No se exige demostrar que la consulta del LLM sea mejor, solo observar qué pasó

Qué se compara



Qué se mantiene igual y qué se mide

- Se mantiene igual: corpus (10 fichas), chunks de 180 palabras, modelo e5-small, FAISS, top-k y qrels
- Solo cambia la consulta, por eso la diferencia se puede atribuir a ella
- Sobre el JSON del LLM se mide:
  - schema_valid_rate: ¿cumple el formato?
  - intención correcta: ¿la intención coincide con la esperada?
- Sobre la recuperación se mide:
  - Recall@1, Recall@3 y Recall@5 de Q0 y de Q1
  - Jaccard del top-3: cuánto coinciden los fragmentos recuperados por ambas

Resultados: el formato del JSON

Métrica	Valor	Qué mide
JSON exacto	0/5	el texto completo es un JSON
JSON parseable	5/5	se puede extraer el JSON del texto
schema_valid_rate	5/5	cumple claves, tipos y valores permitidos
Abstención	0/5	el modelo considera que la necesidad sí se puede responder con estas fichas, así que genera la consulta

- **Interpretación**

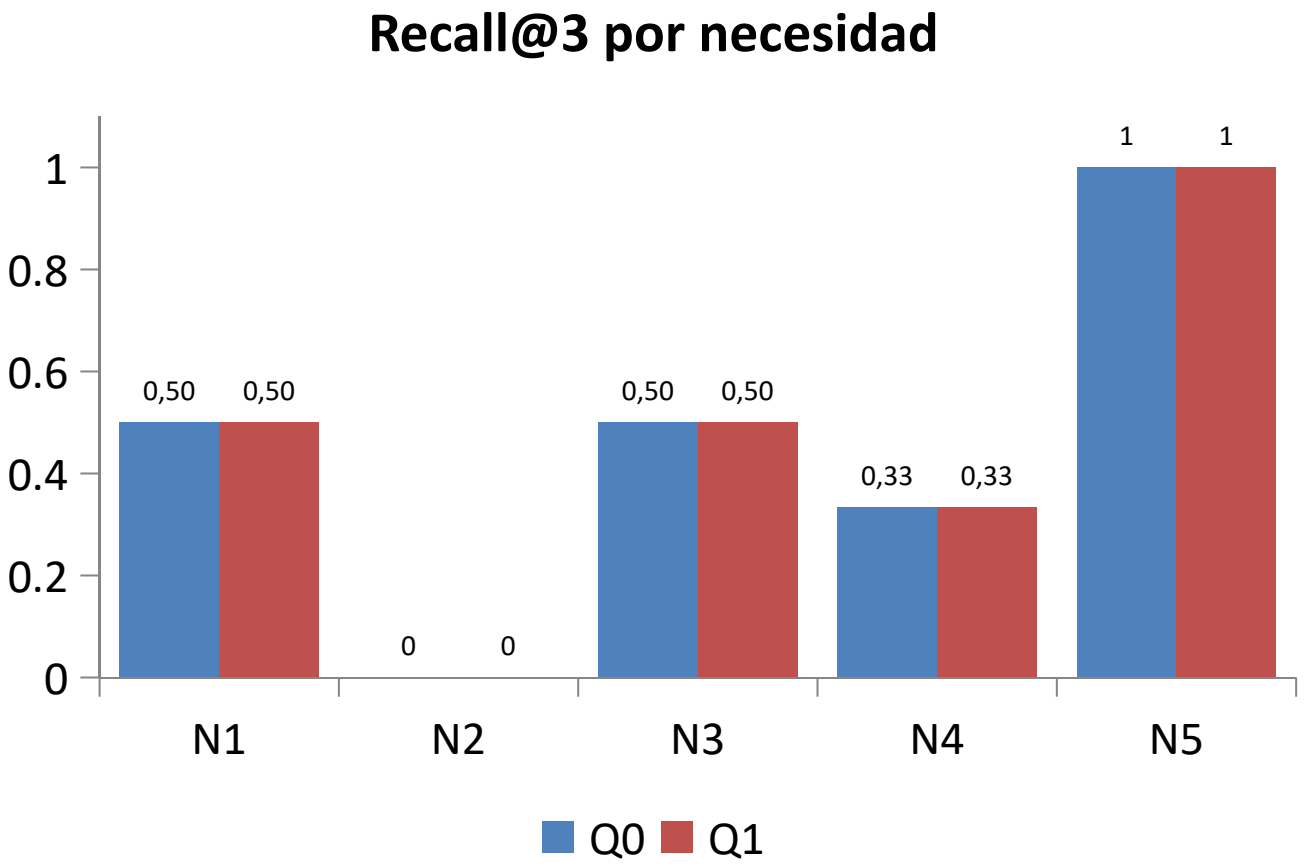
  - El modelo cumple el formato: las 5 salidas son válidas
  - El JSON exacto es 0 porque siempre lo envolvió en un bloque de código; al parsear se recupera
  - En formato no hay problema, pero el schema solo revisa la forma, no si el contenido es correcto

Resultados: la intención del JSON

Necesidad	Intención esperada	Intención del LLM	¿Correcta?
N1	marca_sin_equivalente	marca_sin_equivalente	sí
N2	marca_con_equivalente	marca_con_equivalente	sí
N3	compatibilidad_equipo_existente	competencia	no
N4	competencia	competencia	sí
N5	resultado_adjudicacion	marca_con_equivalente	no

- **Interpretación**
  - Intención correcta en 3 de 5: formato válido no garantiza contenido correcto
  - En N5 (¿quién ganó?) el modelo respondió marca_con_equivalente (posible causa: la palabra Mindray, una marca)
  - Un sistema que filtre por intención buscaría en el lugar equivocado en N3 y N5

Resultados: la recuperación



Consulta	R@1	R@3	R@5
Q0	0,30	0,47	0,53
Q1	0,30	0,47	0,53

- Q0 y Q1 dan los mismos valores
- Jaccard medio del top-3 = 0,90
- Solo N2 cambia de fragmentos

Interpretación: la recuperación

- Q0 y Q1 recuperan lo mismo
  - El LLM copió la necesidad en 4 de 5 casos, por eso el Recall no cambia
  - Jaccard 0,90: casi todos los top-3 son iguales (en N2 comparten 2 de 4 fragmentos)
- El Recall es bajo en las dos consultas
  - Con 5 resultados queda sin encontrar casi la mitad de la evidencia (R@5 = 0,53)
  - El problema está en el recuperador y no en la transformación de la consulta
- Recall@1 ≤ Recall@3 ≤ Recall@5, como debe ser: más resultados cubren más evidencia

Interpretación: por necesidad

Necesidad	R@3 (Q0 y Q1)	Por qué
N1	0,50	encuentra la ficha Cisco, no la de Agilent
N2	0	la evidencia es la frase corta "o equivalente", que el modelo no destaca
N3	0,50	encuentra la ficha Mindray, no la de Epson
N4	0,33	trae un proceso con un solo postor de los tres
N5	1	pregunta por un caso concreto con palabras que están en la ficha

- Las necesidades con evidencia en varias fichas (N1, N3, N4) quedan a medias
- Las que dependen de una frase corta (N2) quedan en 0

Qué pasó con la consulta

- En 4 de 5 necesidades el LLM copió la necesidad tal cual como query
- En N2 la reformuló:
  - Original: Quiero encontrar los requerimientos que mencionan una marca pero permiten ofertar un producto equivalente
  - Q1: ¿Qué requerimientos mencionan una marca pero permiten ofertar un producto equivalente?
  - Cambió uno de los tres fragmentos del top-3 (Jaccard 0,5), pero ninguno era relevante y el R@3 siguió en 0
- En N5 el JSON fue válido pero la intención salió marca_con_equivalente, siendo una pregunta por el ganador

Conclusión

- La consulta estructurada conserva la necesidad, pero no la mejora
  - El modelo pequeño no la reescribe con el vocabulario de las fichas ("buena pro", "número de postores", "o equivalente")
- Un JSON válido no garantiza una intención correcta
  - schema_valid_rate = 1 mide el formato; la intención fue correcta en 3 de 5
- El Recall bajo viene del recuperador, no de la transformación
  - N2 queda en 0 con Q0 y con Q1
- Con 5 necesidades solo se pueden sacar conclusiones sobre estos casos