Experimento 2: tamaño del chunk

PC2 - Tópicos de Ciencia de la Computación 1

¿De qué trata el experimento?

- Pregunta: ¿cómo cambia la recuperación si solo cambia el tamaño de los chunks?
- No interviene el LLM ni ningún prompt: es un experimento sobre el recuperador
- Una ficha se divide en passages (piezas pequeñas) y un chunk agrupa passages consecutivos
  - Chunk pequeño: más chunks, cada uno con menos contexto
  - Chunk grande: menos chunks, cada uno con casi toda la ficha
- Hipótesis: un chunk pequeño aísla la evidencia, pero puede separarla de lo que la identifica

Qué se compara y qué se mantiene igual

Condición	Tamaño objetivo	Chunks resultantes
small	100 palabras	36
baseline	180 palabras	18
large	320 palabras	13

- Se mantiene igual:
  - Las mismas fichas, las mismas 5 consultas (Q0) y los mismos qrels
  - Solapamiento de 1 passage entre chunks vecinos
  - Modelo e5-small, normalización, FAISS y top-k
- Solo cambia el tamaño del chunk

Cómo se parte una ficha: ejemplo D05

Condición	Chunks de D05	Passages que contiene cada chunk
small	2	C01: P01 a P03; C02: P03 a P07
baseline	1	C01: P01 a P07
large	1	C01: P01 a P07

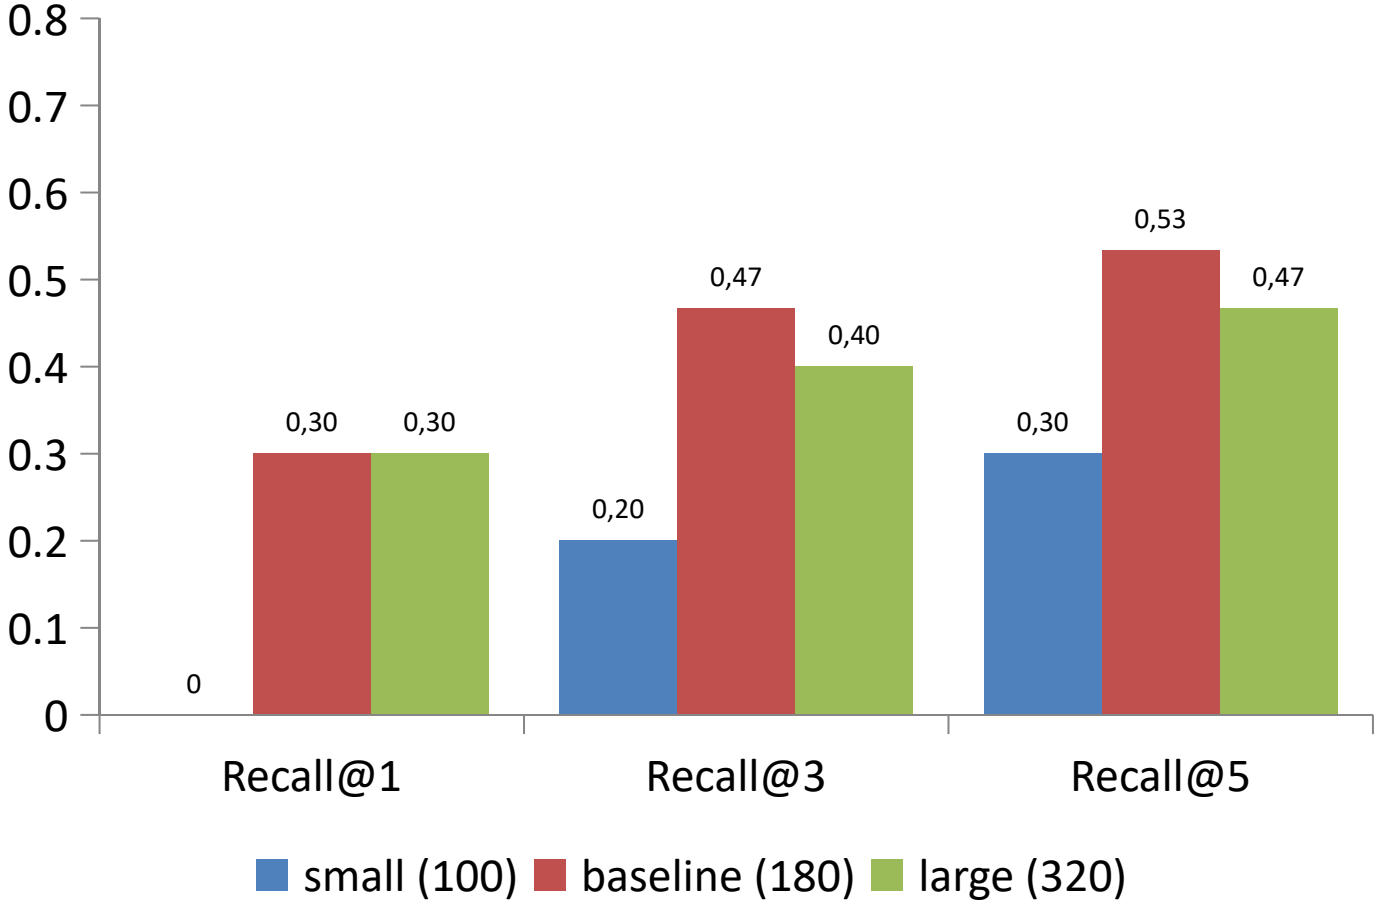
- D05 es la ficha de los reactivos Mindray. Sus passages: P01 convocatoria, P02 ítem, P03 cronograma, P04 documentos, P05 postores, P06 buena pro, P07 contrato
- Con 100 palabras la buena pro (P06) queda en un chunk distinto al del ítem (P02)
- Con 180 y 320 palabras la ficha completa cabe en un solo chunk

Resultados: los chunks que se generaron

Condición	Chunks	Palabras (media)	Palabras (máx.)	Tokens (máx.)	Cortados por tokens
small	36	80	100	236	0
baseline	18	137	180	365	0
large	13	179	257	502	3

- **Interpretación**
  - A mayor tamaño objetivo hay menos chunks, pero cada uno trae más texto
  - El texto del SEACE ocupa unos 2 tokens por palabra y el modelo e5 admite 512 tokens
  - En large, 3 de 13 chunks se cerraron antes de 320 palabras; el más largo tiene 257
  - Así ningún chunk se trunca, pero large significa hasta 320 palabras o 512 tokens

Resultados: Recall según el tamaño del chunk



Condición	R@1	R@3	R@5
small	0	0,20	0,30
baseline	0,30	0,47	0,53
large	0,30	0,40	0,47

- Métrica principal: Recall@3 medio
- baseline (180) es el mejor

Interpretación: el resultado agregado

- small (100) rinde claramente peor: Recall@3 de 0,20 contra 0,47 en baseline
  - Al partir las fichas en tantos chunks, la evidencia queda separada de su contexto
- baseline (180) y large (320) están cerca (0,47 y 0,40)
  - La diferencia es de un solo passage, no alcanza para decir que uno es mejor
- Más chunks no significa mejor recuperación
  - small tiene el doble de chunks que baseline y recupera menos
- El resultado vale para este corpus y estas consultas, no es una regla de chunking

Interpretación: por necesidad

Necesidad	small	baseline	large	Qué pasó
N1	0,50	0,50	0,50	no cambia: encuentra la ficha Cisco, no la de Agilent
N2	0	0	0	0 en las tres: la frase "o equivalente" se diluye
N3	0,50	0,50	0,50	no cambia: encuentra la ficha Mindray, no la de Epson
N4	0	0,33	0	solo baseline trae el chunk con un solo postor
N5	0	1	1	el tamaño ayuda: con 100 palabras la buena pro queda aparte

- Recall@3 por necesidad
  - 3 de 5 necesidades no cambian con el tamaño; el efecto se concentra en N4 y N5

Caso donde el tamaño ayuda: N5

Condición	Primer resultado	Passages que cubre	Recall@3
small	D05-C01-W100 (0,891)	P01 a P03	0
baseline	D05-C01-W180 (0,871)	P01 a P07	1
large	D05-C01-W320 (0,871)	P01 a P07	1

- N5: ¿Qué empresa ganó la compra de reactivos para el equipo Mindray del hospital de Jaén y por cuánto?
  - La evidencia es D05-P06, la buena pro
- Con 100 palabras el primer resultado es la ficha correcta, pero sin la buena pro
  - Documento correcto, fragmento incorrecto: la consulta describe el proceso, la evidencia es otra parte de la ficha
- Con 180 y 320 el chunk trae la ficha completa y el Recall sube a 1

Caso donde el tamaño perjudica: N4

- N4: ¿En qué procesos se presentó un solo postor?
  - Recall@3: small 0, baseline 0,33, large 0
- En baseline el chunk D07-C02 (postores, buena pro y contrato de Vaso de Leche) entra en el puesto 3
- En large ese passage queda dentro del chunk de la ficha completa
  - El chunk baja al puesto 11 y sale del top-3
  - Posible explicación: en la ficha completa pesan más la convocatoria y los alimentos que la frase un solo postor
- Un chunk más grande no siempre ayuda: puede diluir una evidencia corta

Conclusión y limitación

• Con este corpus, estas consultas y estos qrels, el tamaño del chunk cambió el Recall@3 medio de 0,20 (100) a 0,47 (180) y 0,40 (320)

- La diferencia principal está entre small y los otros dos, y la explican N5 y N4

• El tamaño ayuda cuando la evidencia y lo que la identifica deben quedar juntos, y perjudica cuando la evidencia es corta y se diluye

• Limitaciones

- Solo 5 necesidades: un passage mueve el Recall medio entre 0,05 y 0,1
- large está limitado por los 512 tokens del modelo
- No se puede afirmar que un tamaño sea el mejor en general