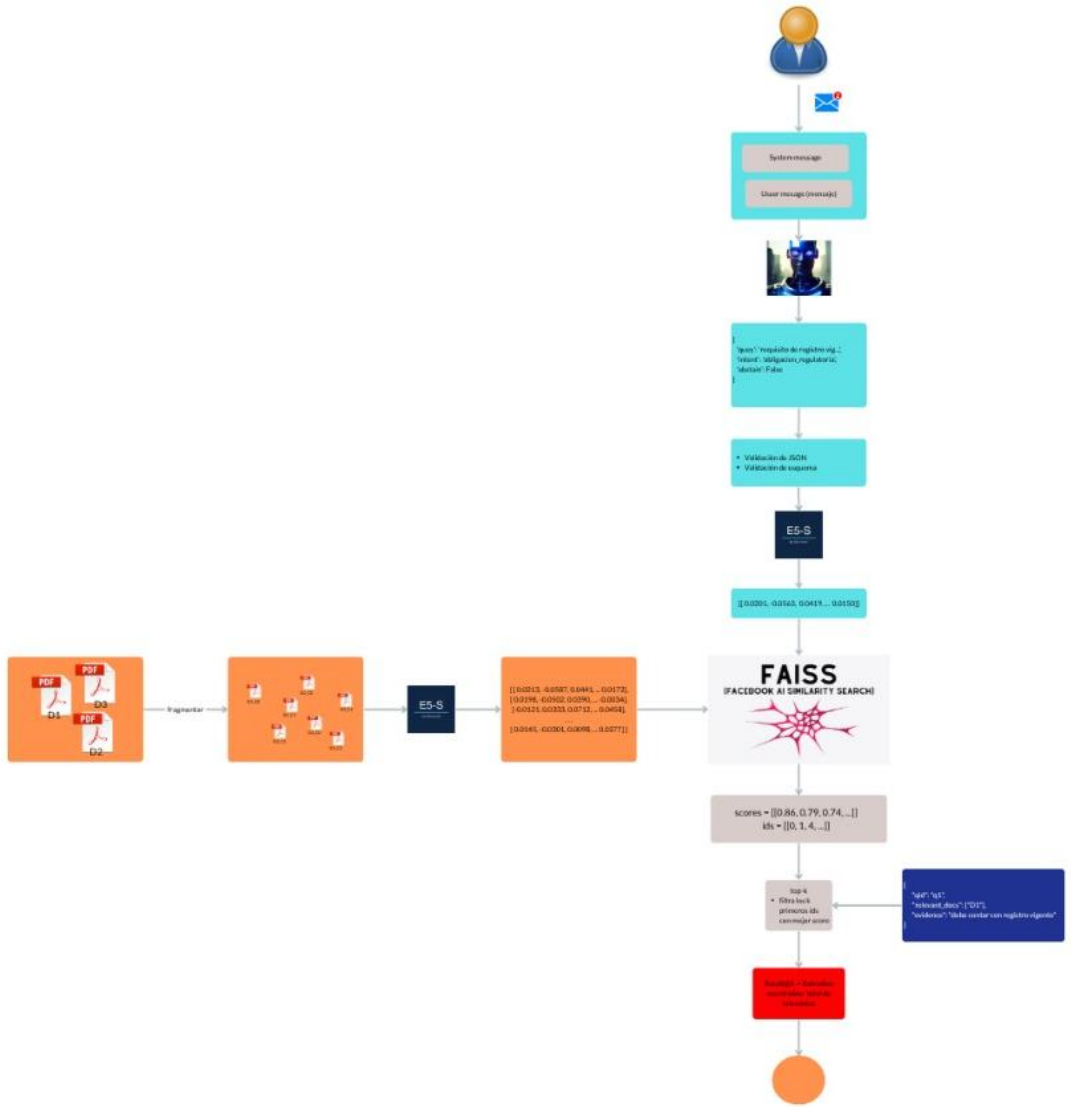
PC2 - Tópicos de Ciencia de la Computación 1

Experimento 1: consulta estructurada | Experimento 2: tamaño del chunk

Diagrama de flujo de la PC2



Cómo leer el diagrama

- Rama de los documentos (izquierda)
  - Fichas → se fragmentan en chunks → e5 convierte cada chunk en un vector → FAISS los guarda
- Rama de la consulta (arriba)
  - Necesidad → prompt (system + user) → LLM → JSON (query, intent, abstain) → validación → e5 → vector
- Búsqueda y evaluación (abajo)
  - FAISS compara la consulta con todos los chunks → scores e ids → top-k → Recall@k con los qrels
- Qué cambia cada experimento
  - Experimento 1: la rama de arriba (consulta original o consulta del LLM)
  - Experimento 2: la rama de la izquierda (tamaño de los chunks: 100, 180 o 320 palabras)

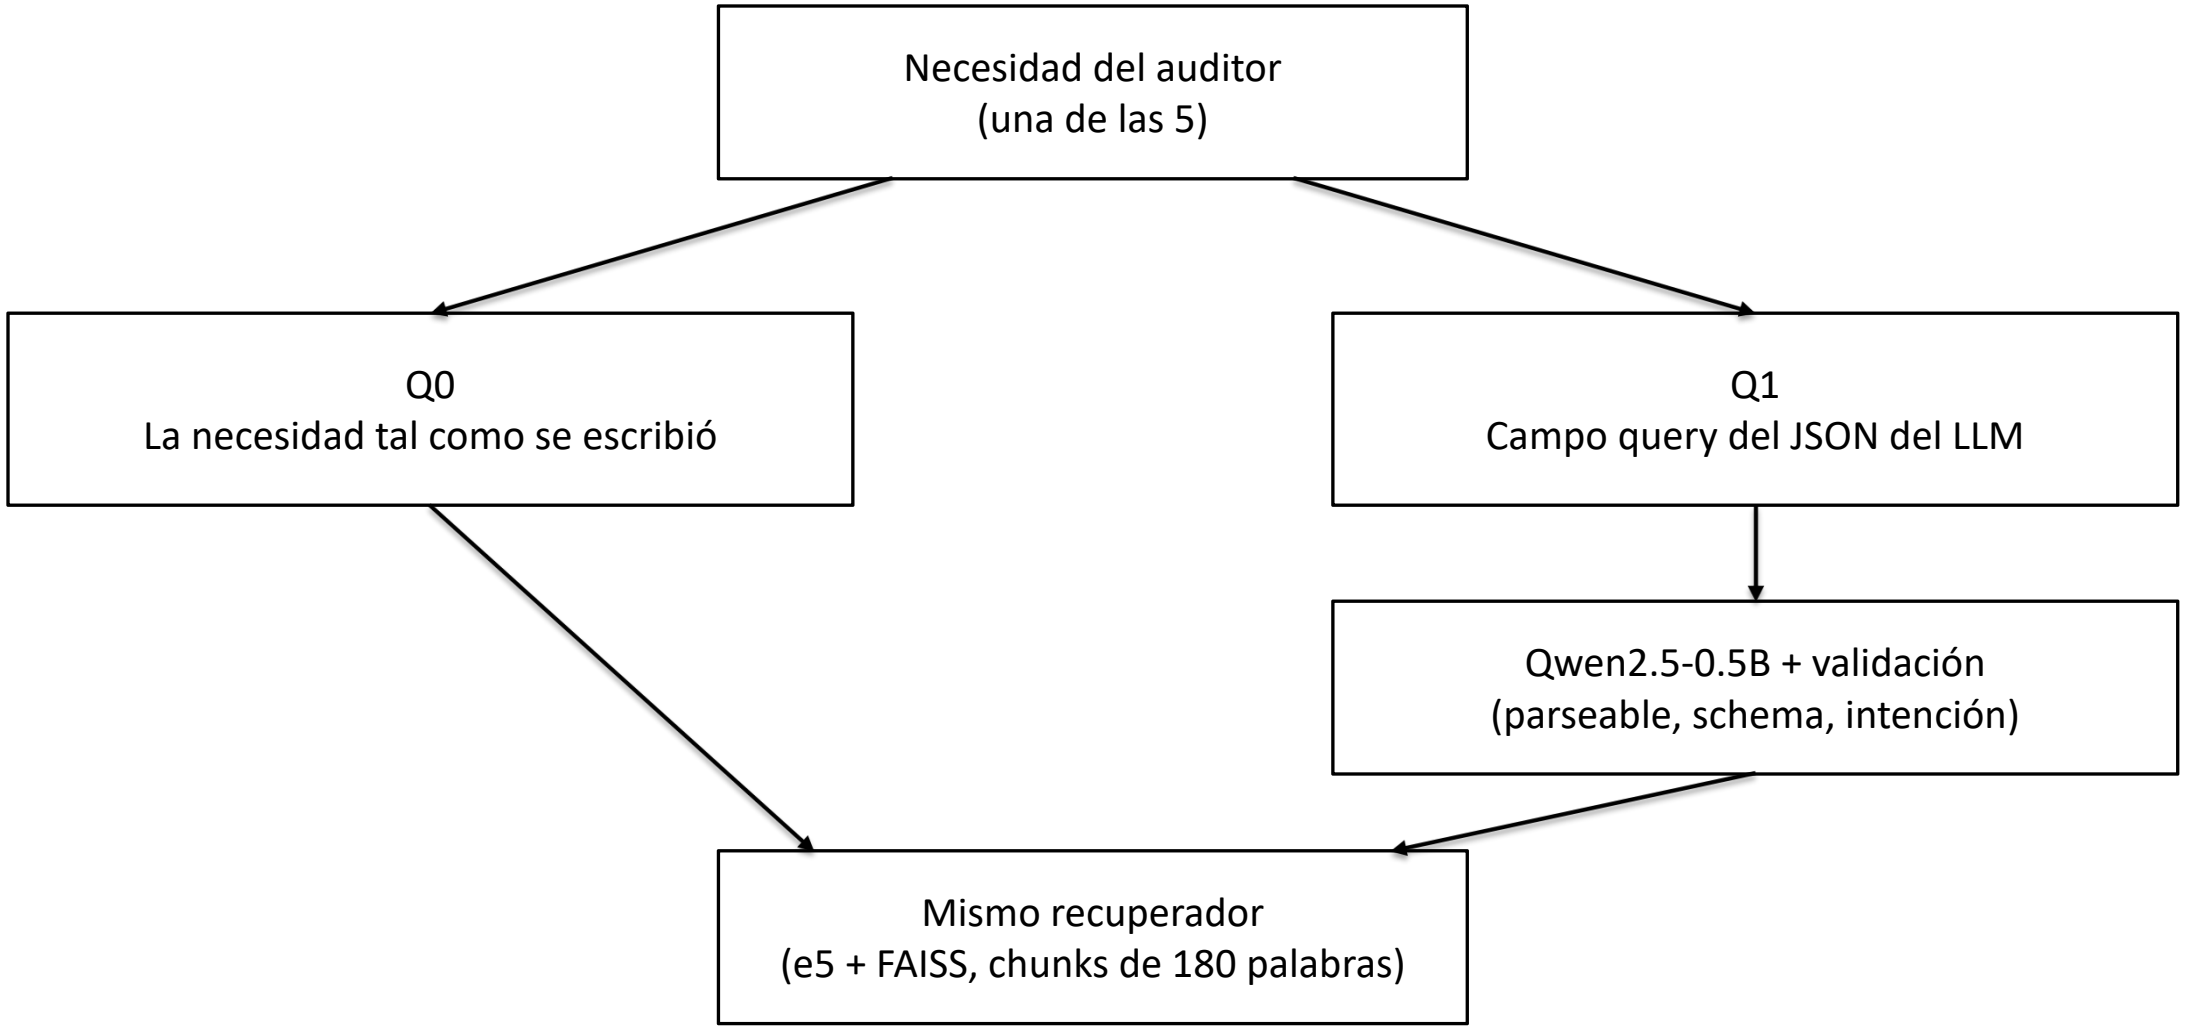
Experimento 1: consulta original vs consulta estructurada

PC2 - Tópicos de Ciencia de la Computación 1

¿De qué trata el experimento?

- El auditor escribe una necesidad de información en lenguaje natural
  - Ejemplo: ¿Qué empresa ganó la compra de reactivos para el equipo Mindray?
- Antes de buscar, un LLM la convierte en una consulta estructurada (un JSON)
- Pregunta: ¿esa transformación conserva, mejora o empeora lo que se quería encontrar?
- No se exige demostrar que la consulta del LLM sea mejor, solo observar qué pasó

Qué se compara



Qué se mantiene igual y qué se mide

- Se mantiene igual: corpus (10 fichas), chunks de 180 palabras, modelo e5-small, FAISS, top-k y qrels
- Solo cambia la consulta, por eso la diferencia se puede atribuir a ella
- Sobre el JSON del LLM se mide:
  - schema_valid_rate: ¿cumple el formato?
  - intención correcta: ¿la intención coincide con la esperada?
- Sobre la recuperación se mide:
  - Recall@1, Recall@3 y Recall@5 de Q0 y de Q1
  - Jaccard del top-3: cuánto coinciden los fragmentos recuperados por ambas

Resultados: el formato del JSON

Métrica	Valor	Qué mide
JSON exacto	0/5	el texto completo es un JSON
JSON parseable	5/5	se puede extraer el JSON del texto
schema_valid_rate	5/5	cumple claves, tipos y valores permitidos
Abstención	0/5	el modelo considera que la necesidad sí se puede responder con estas fichas, así que genera la consulta

- **Interpretación**

  - El modelo cumple el formato: las 5 salidas son válidas

  - El JSON exacto es 0 porque siempre lo envolvió en un bloque de código; al parsear se recupera

  - En formato no hay problema, pero el schema solo revisa la forma, no si el contenido es correcto

Resultados: la intención del JSON

Necesidad	Intención esperada	Intención del LLM	¿Correcta?
N1	marca_sin_equivalente	marca_sin_equivalente	sí
N2	marca_con_equivalente	marca_con_equivalente	sí
N3	compatibilidad_equipo_existente	competencia	no
N4	competencia	competencia	sí
N5	resultado_adjudicacion	marca_con_equivalente	no

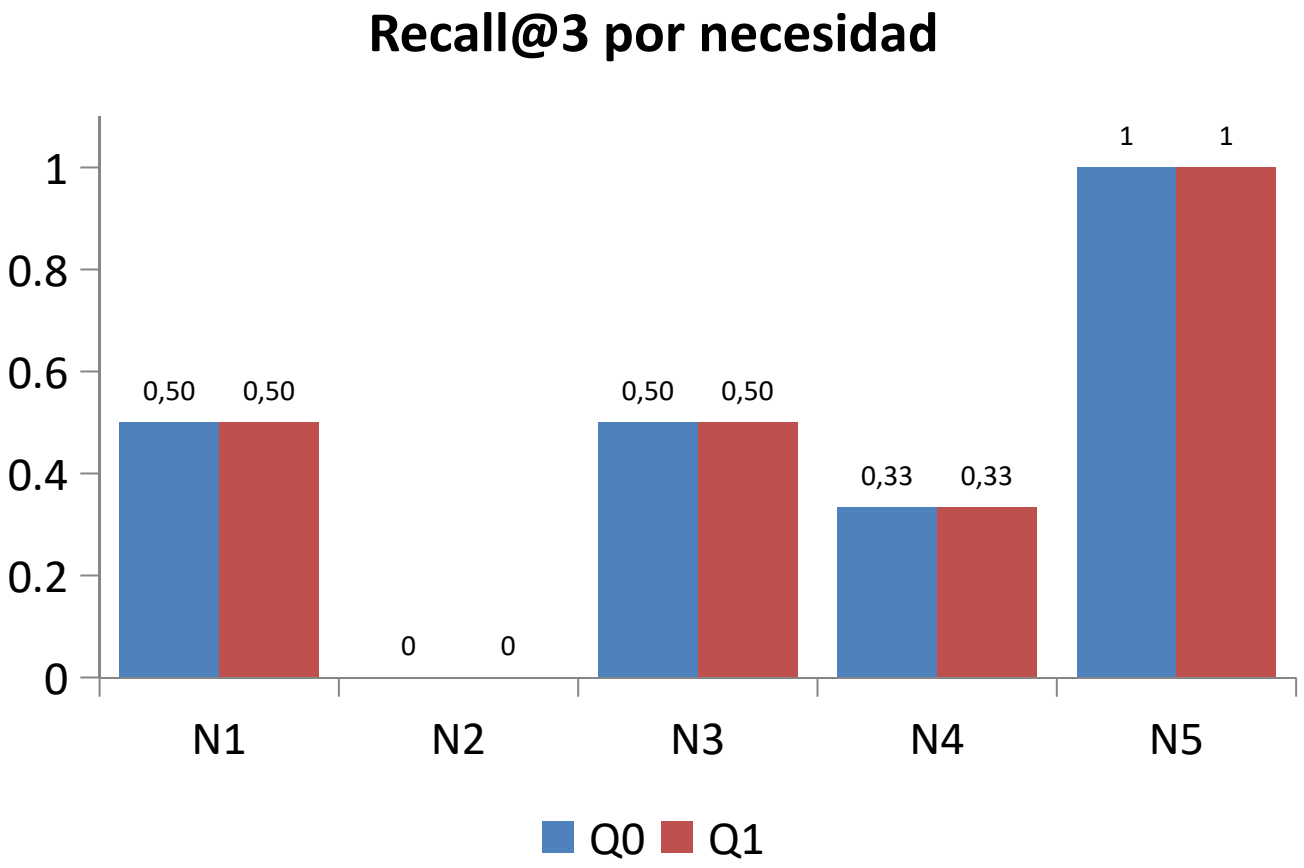
- **Interpretación**

  - Intención correcta en 3 de 5: formato válido no garantiza contenido correcto

  - En N5 (¿quién ganó?) el modelo respondió marca_con_equivalente (posible causa: la palabra Mindray, una marca)

  - Un sistema que filtre por intención buscaría en el lugar equivocado en N3 y N5

Resultados: la recuperación



Consulta	R@1	R@3	R@5
Q0	0,30	0,47	0,53
Q1	0,30	0,47	0,53

- Q0 y Q1 dan los mismos valores
- Jaccard medio del top-3 = 0,90
- Solo N2 cambia de fragmentos

Interpretación: la recuperación

- Q0 y Q1 recuperan lo mismo
  - El LLM copió la necesidad en 4 de 5 casos, por eso el Recall no cambia
  - Jaccard 0,90: casi todos los top-3 son iguales (en N2 comparten 2 de 4 fragmentos)
- El Recall es bajo en las dos consultas
  - Con 5 resultados queda sin encontrar casi la mitad de la evidencia (R@5 = 0,53)
  - El problema está en el recuperador y no en la transformación de la consulta
- Recall@1 ≤ Recall@3 ≤ Recall@5, como debe ser: más resultados cubren más evidencia

Interpretación: por necesidad

Necesidad	R@3 (Q0 y Q1)	Por qué
N1	0,50	encuentra la ficha Cisco, no la de Agilent
N2	0	la evidencia es la frase corta "o equivalente", que el modelo no destaca
N3	0,50	encuentra la ficha Mindray, no la de Epson
N4	0,33	trae un proceso con un solo postor de los tres
N5	1	pregunta por un caso concreto con palabras que están en la ficha

- Las necesidades con evidencia en varias fichas (N1, N3, N4) quedan a medias
- Las que dependen de una frase corta (N2) quedan en 0

Qué pasó con la consulta

- En 4 de 5 necesidades el LLM copió la necesidad tal cual como query
- En N2 la reformuló:
  - Original: Quiero encontrar los requerimientos que mencionan una marca pero permiten ofertar un producto equivalente
  - Q1: ¿Qué requerimientos mencionan una marca pero permiten ofertar un producto equivalente?
  - Cambió uno de los tres fragmentos del top-3 (Jaccard 0,5), pero ninguno era relevante y el R@3 siguió en 0
- En N5 el JSON fue válido pero la intención salió marca_con_equivalente, siendo una pregunta por el ganador

Conclusión

- La consulta estructurada conserva la necesidad, pero no la mejora
  - El modelo pequeño no la reescribe con el vocabulario de las fichas ("buena pro", "número de postores", "o equivalente")
- Un JSON válido no garantiza una intención correcta
  - schema_valid_rate = 1 mide el formato; la intención fue correcta en 3 de 5
- El Recall bajo viene del recuperador, no de la transformación
  - N2 queda en 0 con Q0 y con Q1
- Con 5 necesidades solo se pueden sacar conclusiones sobre estos casos

Experimento 2: tamaño del chunk

PC2 - Tópicos de Ciencia de la Computación 1

¿De qué trata el experimento?

- Pregunta: ¿cómo cambia la recuperación si solo cambia el tamaño de los chunks?
- No interviene el LLM ni ningún prompt: es un experimento sobre el recuperador
- Una ficha se divide en passages (piezas pequeñas) y un chunk agrupa passages consecutivos
  - Chunk pequeño: más chunks, cada uno con menos contexto
  - Chunk grande: menos chunks, cada uno con casi toda la ficha
- Hipótesis: un chunk pequeño aísla la evidencia, pero puede separarla de lo que la identifica

Qué se compara y qué se mantiene igual

Condición	Tamaño objetivo	Chunks resultantes
small	100 palabras	36
baseline	180 palabras	18
large	320 palabras	13

- Se mantiene igual:
  - Las mismas fichas, las mismas 5 consultas (Q0) y los mismos qrels
  - Solapamiento de 1 passage entre chunks vecinos
  - Modelo e5-small, normalización, FAISS y top-k
- Solo cambia el tamaño del chunk

Cómo se parte una ficha: ejemplo D05

Condición	Chunks de D05	Passages que contiene cada chunk
small	2	C01: P01 a P03; C02: P03 a P07
baseline	1	C01: P01 a P07
large	1	C01: P01 a P07

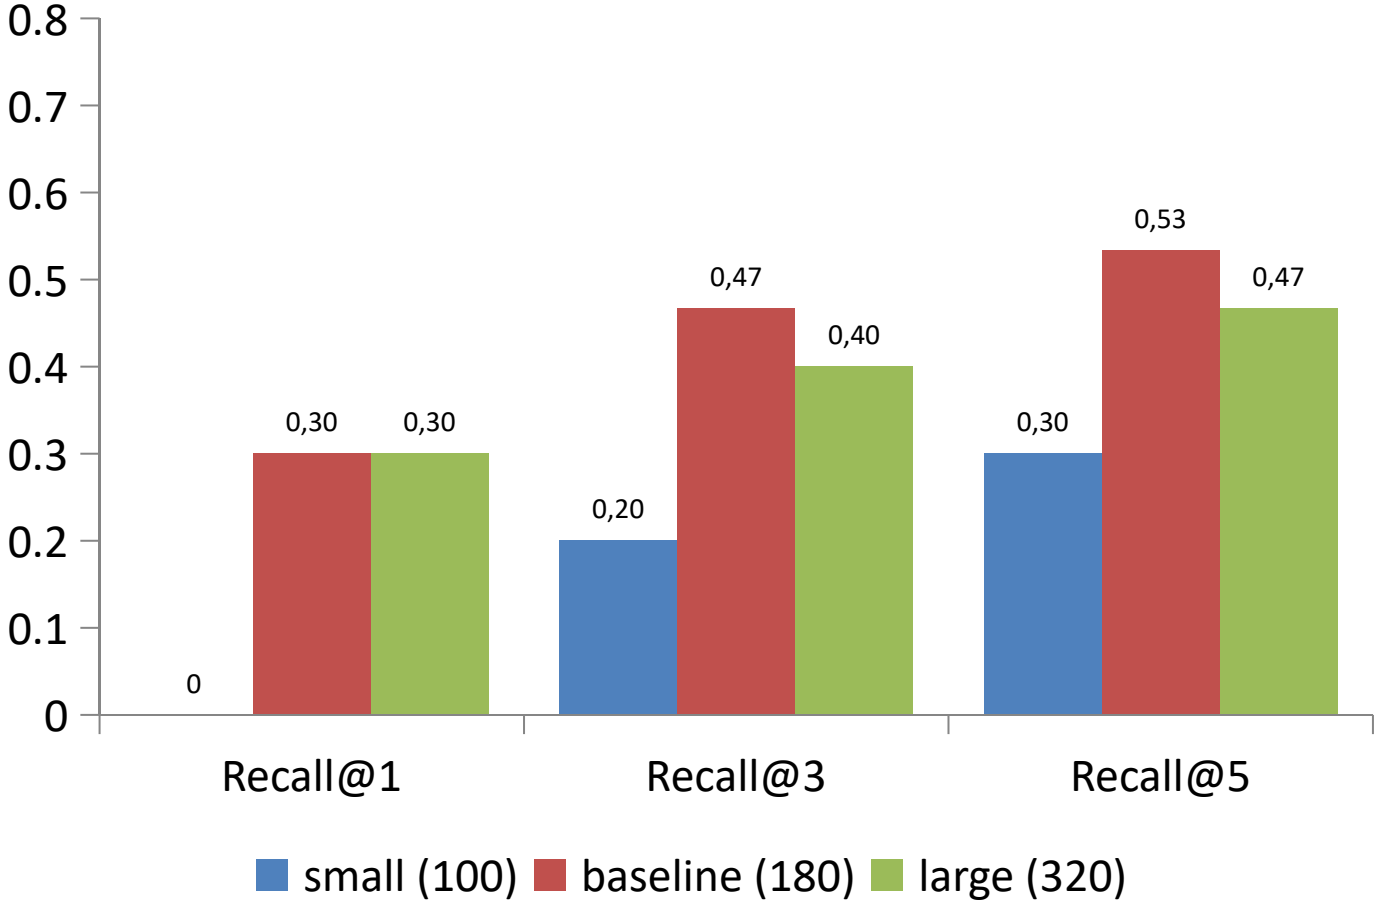
- D05 es la ficha de los reactivos Mindray. Sus passages: P01 convocatoria, P02 ítem, P03 cronograma, P04 documentos, P05 postores, P06 buena pro, P07 contrato
- Con 100 palabras la buena pro (P06) queda en un chunk distinto al del ítem (P02)
- Con 180 y 320 palabras la ficha completa cabe en un solo chunk

Resultados: los chunks que se generaron

Condición	Chunks	Palabras (media)	Palabras (máx.)	Tokens (máx.)	Cortados por tokens
small	36	80	100	236	0
baseline	18	137	180	365	0
large	13	179	257	502	3

- **Interpretación**
  - A mayor tamaño objetivo hay menos chunks, pero cada uno trae más texto
  - El texto del SEACE ocupa unos 2 tokens por palabra y el modelo e5 admite 512 tokens
  - En large, 3 de 13 chunks se cerraron antes de 320 palabras; el más largo tiene 257
  - Así ningún chunk se trunca, pero large significa hasta 320 palabras o 512 tokens

Resultados: Recall según el tamaño del chunk



Condición	R@1	R@3	R@5
small	0	0,20	0,30
baseline	0,30	0,47	0,53
large	0,30	0,40	0,47

- Métrica principal: Recall@3 medio
- baseline (180) es el mejor

Interpretación: el resultado agregado

- small (100) rinde claramente peor: Recall@3 de 0,20 contra 0,47 en baseline
  - Al partir las fichas en tantos chunks, la evidencia queda separada de su contexto
- baseline (180) y large (320) están cerca (0,47 y 0,40)
  - La diferencia es de un solo passage, no alcanza para decir que uno es mejor
- Más chunks no significa mejor recuperación
  - small tiene el doble de chunks que baseline y recupera menos
- El resultado vale para este corpus y estas consultas, no es una regla de chunking

Interpretación: por necesidad

Necesidad	small	baseline	large	Qué pasó
N1	0,50	0,50	0,50	no cambia: encuentra la ficha Cisco, no la de Agilent
N2	0	0	0	0 en las tres: la frase "o equivalente" se diluye
N3	0,50	0,50	0,50	no cambia: encuentra la ficha Mindray, no la de Epson
N4	0	0,33	0	solo baseline trae el chunk con un solo postor
N5	0	1	1	el tamaño ayuda: con 100 palabras la buena pro queda aparte

- Recall@3 por necesidad
  - 3 de 5 necesidades no cambian con el tamaño; el efecto se concentra en N4 y N5

Caso donde el tamaño ayuda: N5

Condición	Primer resultado	Passages que cubre	Recall@3
small	D05-C01-W100 (0,891)	P01 a P03	0
baseline	D05-C01-W180 (0,871)	P01 a P07	1
large	D05-C01-W320 (0,871)	P01 a P07	1

- N5: ¿Qué empresa ganó la compra de reactivos para el equipo Mindray del hospital de Jaén y por cuánto?
  - La evidencia es D05-P06, la buena pro
- Con 100 palabras el primer resultado es la ficha correcta, pero sin la buena pro
  - Documento correcto, fragmento incorrecto: la consulta describe el proceso, la evidencia es otra parte de la ficha
- Con 180 y 320 el chunk trae la ficha completa y el Recall sube a 1

Caso donde el tamaño perjudica: N4

- N4: ¿En qué procesos se presentó un solo postor?
  - Recall@3: small 0, baseline 0,33, large 0
- En baseline el chunk D07-C02 (postores, buena pro y contrato de Vaso de Leche) entra en el puesto 3
- En large ese passage queda dentro del chunk de la ficha completa
  - El chunk baja al puesto 11 y sale del top-3
  - Posible explicación: en la ficha completa pesan más la convocatoria y los alimentos que la frase un solo postor
- Un chunk más grande no siempre ayuda: puede diluir una evidencia corta

Conclusión y limitación

• Con este corpus, estas consultas y estos qrels, el tamaño del chunk cambió el Recall@3 medio de 0,20 (100) a 0,47 (180) y 0,40 (320)

- La diferencia principal está entre small y los otros dos, y la explican N5 y N4

• El tamaño ayuda cuando la evidencia y lo que la identifica deben quedar juntos, y perjudica cuando la evidencia es corta y se diluye

• Limitaciones

- Solo 5 necesidades: un passage mueve el Recall medio entre 0,05 y 0,1
- large está limitado por los 512 tokens del modelo
- No se puede afirmar que un tamaño sea el mejor en general