PC2 - Tópicos de Ciencia de la Computación 1

De una consulta estructurada a recuperación densa verificable sobre fichas OCDS de contrataciones públicas

1 Necesidad

2 JSON validado

3 e5 + FAISS

4 Recall@k

Tema: sistema multi-agente LLM para detectar requisitos direccionados en bases de contrataciones del Estado (continuación de la PC1)

Problema y necesidad de recuperación

Antes de decidir si un requisito está direccionado, el sistema necesita encontrar la evidencia en la ficha

Corpus

10 fichas reales del SEACE (OCDS 2026, convocatorias 2024-2026)

92 passages: convocatoria, ítems, cronograma, documentos, postores, buena pro y contrato

Cubre las 4 señales de la rúbrica de la PC1, 3 procesos con un solo postor y una trampa léxica (ladrillo ADOBE)

Qrels sobre passage_id: no cambian cuando cambia el tamaño del chunk

5 necesidades de información (Q0) y su evidencia

N1	**Marca o código sin "o equivalente"**	Cisco, Agilent |G| = 2
N2	**Marca que sí acepta "o equivalente"**	Oracle, IBM Power |G| = 4
N3	**Insumos para un equipo que ya tiene la entidad**	Mindray, Epson |G| = 4
N4	**Procesos con un solo postor**	3 passages de postores |G| = 3
N5	**Ganador y monto de los reactivos Mindray**	1 passage de buena pro |G| = 1

Pipeline: consulta estructurada → embeddings → FAISS

Cada etapa es una pieza distinta: encoder ≠ índice ≠ almacén ≠ recuperador

1 **Necesidad**
texto del auditor (Q0)

→

2 **Qwen2.5-0.5B**
greedy · prompt con TAREA / NECESIDAD / CONTEXTO

→

3 **JSON Schema**
parseable → cumple el schema → intención

→

4 **e5-small**
"query: …" / "passage: …"
384 dim · L2 · minúsculas

→

5 **IndexFlatIP**
producto interno exacto = coseno (vectores L2)

→

6 **top-k → Recall@k**
k = 1, 3, 5 sobre los passages relevantes

Salida del LLM validada (N4)

```
{"query": "¿En qué procesos se presentó
           un solo postor?",
 "intent": "competencia",
 "abstain": false}
```

parseable ✓ · schema-valid ✓ · intención correcta ✓
al encoder: "query: ¿en qué procesos se presentó un solo postor?"

Chunk	target_words	chunks	palabras media	tokens máx.
small	100	36	80	236
baseline	180	18	137	365
large	320	13	179	502

Sin truncación: el texto SEACE ocupa ~2 tokens por palabra; el chunker se cierra antes de 512 tokens (3 de 13 chunks de la condición large).

Dos experimentos, una variable a la vez

La métrica principal de la discusión es mean Recall@3

1 Exp. 1 · Consulta

basado en prompts

Compara	Q0 = necesidad original vs Q1 = campo query del JSON del LLM
Fijos	corpus · chunk 180 palabras · overlap 1 · e5-small · L2 · IndexFlatIP · k
Mide	schema_valid_rate, intención correcta y Recall@1/3/5 de Q0 vs Q1
Hipótesis	la consulta estructurada conserva la necesidad; no se exige que la mejore

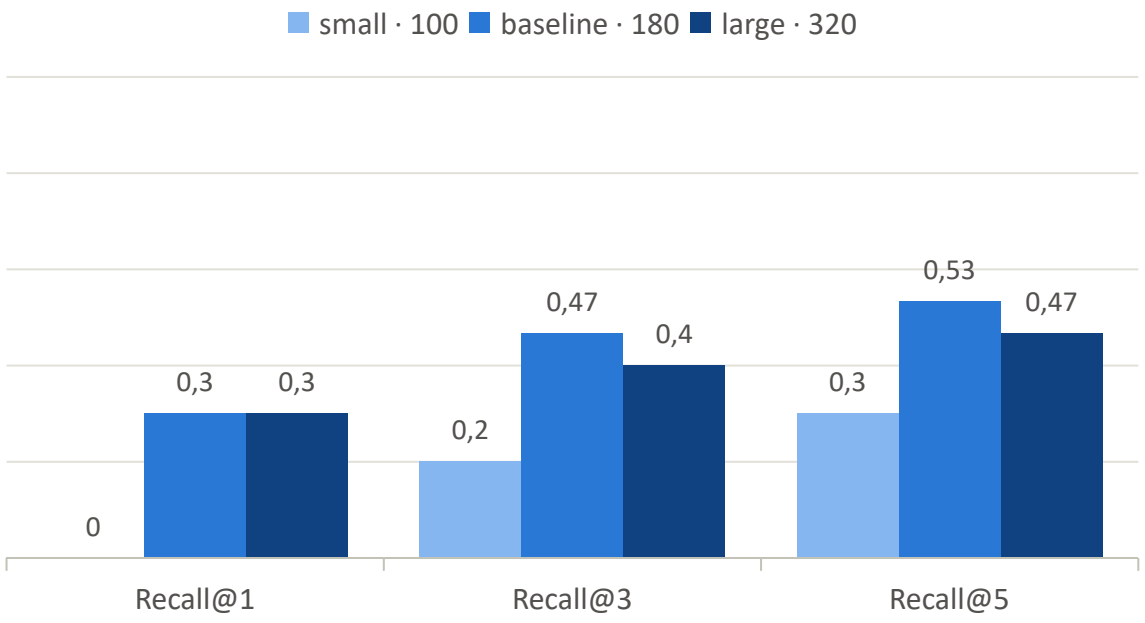
2 Exp. 2 · Tamaño del chunk

sin prompts

Compara	small = 100 · baseline = 180 · large = 320 palabras
Fijos	corpus · consultas Q0 · qrels · overlap 1 · e5-small · L2 · producto interno · IndexFlatIP · k
Mide	Recall@1, Recall@3 (principal) y Recall@5, y el cambio por necesidad
Hipótesis	el chunk pequeño aísla un ítem, pero puede separar la evidencia de lo que la identifica

Resultados y error de recuperación

Con chunks de 180 palabras se recupera más evidencia; Q1 recupera lo mismo que Q0 (mean R@3 = 0,47 en ambas)



R@3	small	base	large
N1	0,5	0,5	0,5
N2	0	0	0
N3	0,5	0,5	0,5
N4	0	0,33	0
N5	0	1	1

N5 · el tamaño del chunk ayuda

Con 100 palabras el top-1 es la ficha correcta (D05, 0,891), pero el chunk tiene convocatoria + ítem: la buena pro quedó en otro chunk → R@3 = 0.

Con 180 la ficha entera cabe en un chunk → R@1 = 1. Documento ≠ fragmento.

N2 · error con cualquier tamaño

La evidencia es una frase corta ("o equivalente") dentro de chunks de ~150 palabras: el embedding la diluye.

Top-10 entre 0,851 y 0,838; el chunk relevante de D04 queda 8.º (0,840). Pide señal léxica: BM25 / híbrido.

Limitación y conclusión

Bajo este corpus, estas 5 necesidades, estos qrels y e5-small con IndexFlatIP

5/5

salidas de Q1 schema-valid,
pero intención correcta 3/5

0,20 → 0,47

mean Recall@3 al pasar
de 100 a 180 palabras

0

Recall@3 de N2 con los
tres tamaños de chunk

Conclusión

El LLM conserva la necesidad (casi la copia) y no mejora la recuperación; el JSON válido no garantiza la intención correcta.

El tamaño del chunk importa cuando la evidencia y lo que la identifica están en passages distintos.

Limitación

5 necesidades y 10 fichas: un passage mueve el Recall medio entre 0,05 y 0,1. Qrels de un solo anotador.

"large" quedó limitado por la ventana de 512 tokens (máx. real 257 palabras). No se generaliza un tamaño de chunk óptimo.